

Codex 利用はパンクするのかしら？

ログデータと待ち行列理論 ($M/G/1$) で解き明かす LLM キャパシティの限界

1. Executive Summary (結論)

- 課題

- チーム内で Codex 利用が増えると、突然 API のレートリミット (429 Too Many Requests) が発生する。

- 原因

- Codex のログを解析した結果、1回のやり取りの平均トークン数が **約 6.5 万トークン** と超巨大であることが判明。

- 数理モデルでの検証 (OR: 待ち行列理論)

- 実測データから開発者の行動パターンを抽出し、 $M/G/1$ モデルでシミュレーション。

- 結論

- 一般的な **50万 TPM 制限** の環境では、**たった 7 人の同時利用で API がパンク (100%突破)** する。

2. 背景：Codex 特有のトークン消費構造

- 通常の Chat LLM との違い
 - 一般的なチャット: 1回あたり数千トークン程度。
 - Codex (TUI / IDE): 会話が長くなると **過去の文脈・関連コード全文を毎リクエスト添付** する。
- ログデータ（Grafana Loki）の実態
 - `input_token_count` : 平均 65,316 トークン（全体の99.5%以上を占める）
 - `output_token_count` : 平均 278 トークン
 - 合計 (S): 1リクエストあたり平均 約 65,595 トークン
- 🖱️ 1回のメッセージ送信自体が、非常に重いネットワーク・帯域負荷になっている！


3. 数理モデリング： $M/G/1$ 待ち行列モデルの適用

API の帯域制限 (TPM: Tokens Per Minute) を 1 つの「窓口」と見立てて定式化。

- **到着過程 (M - Markovian):**
 - 開発者のリクエスト発生はランダム (ポアソン過程)。
 - 実測値: 1人あたり $\lambda_1 = 1.244 \text{ req/min}$ (約 48 秒に 1 回呼び出し)。
- **サービス時間 (G - General):**
 - 1リクエストで消費するトークン量 S 。
 - 実測値: 平均 $E[S] = 65,595$ トークン / 分散 $Var[S] = 146.5 \times 10^6$ 。
- **窓口 (1):**
 - API 全体の処理容量制限上限 (TPM_{Limit})。

4. シミュレーション結果：同時利用人数 vs TPM 利用率

- TPM 制限 50 万（青線）
 - 限界値: 6 人
 - 7 人で利用率 114.2% となりパンク。
- TPM 制限 100 万（黄線）
 - 限界値: 12 人
- TPM 制限 200 万（緑線）
 - 限界値: 24 人



5. ボトルネックの構造解剖

なぜこれほど少ない人数でパンクしてしまうのか？

1. 高密度な要求レート

- 開発者 1 人あたり、1 分間に約 **8.1 万トークン** の帯域を要求している。

2. 分散（ばらつき）の影響

- コンテキスト長は 3.8 万 ～ 8.7 万トークンまで大きく変動する。
- $M/G/1$ モデルの特性上、消費量のばらつき (C_v^2) が大きいほど、瞬間的な待ち時間・帯域溢れが発生しやすくなる。

6. OR的アプローチによる改善ソリューション案

精神論（「節約しよう」）ではなく、**構造的（システム・運用）な解決**を提案。

① サービス時間 $E[S]$ の縮小（システム改善）

- **コンテキスト要約 / Sliding Window の導入**
 - 過去履歴を圧縮し、1リクエストの平均トークン数を 6.5 万 → **3 万** に削れば、同じ TPM 制限のまま**収容人数を 2 倍（12人）に拡張可能**。

② 到着率 λ の平準化（運用・自動化改善）

- **バックグラウンド処理の分散**
 - 自動テストや CI/CD からの大量リクエストを夜間にシフトし、日中の人間の作業帯域を確保。

7. まとめと今後の展望

- 本研究の成果

- Grafana Loki の可観測性ログから、 $M/G/1$ 待ち行列モデルを構築。
- 「チームで何人 Codex を使うとパンクするか」を定量的（数学的）に可視化した。

- 今後のアクション

- i. システムプロンプト・履歴送信ロジックの最適化によるトークン削減の検証。
- ii. 組織規模に応じた適切な API Tier（TPM 枠）の選定指標としての活用。

Thank you!

Questions & Discussion